# REQUERIMIENTOS

## Sistema Privado de Gestion y Consulta Documental

*Aplicacion web desarrollada con HTML, CSS, PHP y MySQL*

*Version 2.0 - Sin componentes de inteligencia artificial*

*Documento de analisis y especificacion de requerimientos*

# Control de versiones del documento

| Version | Fecha | Descripcion del cambio |
|---|---|---|
| 1.0 | 23/09/2026 | Version inicial: sistema de consulta documental con inteligencia artificial (RAG, embeddings, chat en lenguaje natural). |
| 2.0 | 30/09/2026 | Eliminacion total de los componentes de inteligencia artificial. Tecnologias reducidas a HTML, CSS, PHP y MySQL (Workbench). La consulta documental pasa a resolverse mediante busqueda por palabras clave y filtros avanzados. |

**Alcance del cambio de la version 2.0**

Se retiraron por completo el motor RAG, los embeddings, la base vectorial, el modelo de lenguaje, el chat conversacional y el reconocimiento optico de caracteres (OCR). El sistema conserva la gestion documental, el control de acceso por roles, la trazabilidad y las copias de seguridad, pero la recuperacion de informacion se realiza con mecanismos deterministas de busqueda sobre texto, sin ninguna inferencia automatica.

# Contenido

1. Introduccion
2. Descripcion de la necesidad
3. Planteamiento del problema
4. Objetivos
5. Alcance
6. Actores del sistema
7. Requerimientos funcionales
8. Requerimientos no funcionales
9. Reglas de negocio
10. Casos de uso principales
11. Arquitectura conceptual
12. Seguridad
13. Flujo de la consulta documental
14. Infraestructura y tecnologia
15. Modelo de datos
16. Criterios de aceptacion
17. Riesgos
18. Fases del proyecto
19. Informacion pendiente de validar

# 1. Introduccion

El presente documento define los requerimientos para un sistema privado de gestion y consulta documental. La solucion permite a una organizacion centralizar sus documentos institucionales, controlar el acceso por roles y areas, y localizar informacion mediante un buscador por palabras clave con filtros avanzados.

La aplicacion esta construida exclusivamente con tecnologias web estandar: HTML para la estructura, CSS para la presentacion, PHP para la logica de servidor y MySQL como motor de base de datos, administrado mediante MySQL Workbench. No incorpora componentes de inteligencia artificial.

**Nota sobre el alcance tecnologico**

Este documento reemplaza la version 1.0, que contemplaba un sistema de consulta basado en inteligencia artificial. En la version actual no existe chat conversacional, ni generacion automatica de respuestas, ni modelos de lenguaje. Toda la informacion que el usuario recibe proviene directamente de los documentos registrados por la organizacion.

# 2. Descripcion de la necesidad

La organizacion administra un volumen elevado de documentos que dificulta la consulta manual, el acceso oportuno a informacion especifica y la trazabilidad de las operaciones. Los documentos se encuentran dispersos entre carpetas compartidas, correos electronicos y archivos locales, sin un control uniforme de acceso ni un registro de quien consulto que.

Se requiere un repositorio documental centralizado que permita:

- Registrar cada documento con metadatos completos y verificables.
- Clasificar los documentos por categoria, caso, area y etiquetas.
- Restringir el acceso segun el rol y el area del usuario.
- Localizar documentos rapidamente mediante un buscador por palabras clave.
- Conservar el historial de versiones de cada documento.
- Registrar en una bitacora todas las operaciones criticas.
- Generar copias de seguridad recuperables.

# 3. Planteamiento del problema

El alto volumen documental y la ausencia de un repositorio controlado generan las siguientes consecuencias:

| Situacion actual | Consecuencia |
|---|---|
| Documentos dispersos en multiples ubicaciones | Perdida de tiempo en la busqueda manual y dificultad para localizar antecedentes. |
| Ausencia de control de acceso | Documentos reservados al alcance de personal no autorizado, con riesgo de incumplimiento normativo. |
| Sin registro de operaciones | Imposibilidad de auditar quien consulto, modifico o elimino un documento y en que momento. |
| Multiples versiones sin control | Uso de versiones desactualizadas y riesgo de omitir informacion relevante. |
| Sin respaldos sistematicos | Riesgo de perdida definitiva de informacion institucional. |

# 4. Objetivos

## 4.1. Objetivo general

Disenar y desarrollar un sistema privado de gestion y consulta documental que permita a los usuarios autorizados centralizar, clasificar, localizar y consultar la informacion institucional, con control de acceso por roles, trazabilidad completa de las operaciones y mecanismos de respaldo, utilizando unicamente HTML, CSS, PHP y MySQL.

## 4.2. Objetivos especificos

1. Centralizar los documentos institucionales en un repositorio unico y controlado.
2. Permitir la carga, clasificacion, actualizacion, versionado y retiro de documentos.
3. Implementar autenticacion y control de acceso basado en roles y areas.
4. Desarrollar un buscador por palabras clave con filtros avanzados.
5. Extraer el texto de los archivos cargados para ampliar la busqueda al contenido.
6. Registrar el historial de versiones de cada documento.
7. Mantener una bitacora de auditoria de todas las acciones criticas.
8. Generar y restaurar copias de seguridad de la base de datos.
9. Proveer indicadores y reportes exportables sobre el inventario documental.
10. Garantizar la integridad de los archivos mediante verificacion de hash.

**Objetivos retirados de la version anterior**

Se elimina el objetivo de "implementar recuperacion semantica de fragmentos" y el de "generar respuestas basadas en contenido recuperado". La busqueda actual es lexica y determinista: localiza coincidencias exactas de terminos en los metadatos y en el texto de los documentos.

# 5. Alcance

## 5.1. Incluye

| Modulo | Descripcion |
|---|---|
| Autenticacion | Inicio y cierre de sesion con credenciales validadas, control de intentos fallidos y cierre automatico por inactividad. |
| Gestion de usuarios | Creacion, edicion, activacion, desactivacion y bloqueo de cuentas. |
| Roles y permisos | Tres niveles de acceso (consulta, gestion, administracion) y matriz de permisos por modulo. |
| Areas | Definicion de dependencias que segmentan el acceso a los documentos. |
| Carga documental | Registro de documentos con validacion de formato, peso, tipo real e integridad del archivo. |
| Metadatos | Titulo, codigo, descripcion, categoria, caso, area, autor, fecha, nivel de confidencialidad, palabras clave y etiquetas. |
| Clasificacion | Organizacion por categorias, casos o expedientes, areas y etiquetas. |
| Procesamiento de texto | Extraccion del contenido de archivos PDF, DOCX, XLSX y TXT para ampliar el alcance de la busqueda. |
| Versionado | Conservacion del historial completo de archivos de cada documento. |
| Busqueda | Busqueda por palabras clave sobre metadatos y contenido, con puntuacion de coincidencia y visualizacion del fragmento encontrado. |
| Filtros avanzados | Filtrado por categoria, area, caso, estado, confidencialidad, etiqueta, responsable y rango de fechas. |
| Historial de consultas | Registro de cada busqueda realizada, con tiempo de respuesta y resultados obtenidos. |
| Auditoria | Bitacora de accesos, cargas, modificaciones, descargas y eliminaciones, con estado anterior y posterior. |
| Respaldo | Generacion y descarga de copias de seguridad en formato SQL. |
| Reportes | Indicadores de uso, inventario documental y exportacion a CSV. |
| Control de integridad | Verificacion mediante hash SHA-256 en cada descarga. |

## 5.2. No incluye

Los siguientes elementos quedan expresamente fuera del alcance de esta version:

| Elemento excluido | Justificacion |
|---|---|
| Inteligencia artificial | No se incorpora ningun modelo de lenguaje, red neuronal ni servicio de inferencia. El sistema fue redefinido para operar sin IA. |
| Chat conversacional | No existe una interfaz de dialogo. La consulta se realiza mediante un formulario de busqueda con palabras clave y filtros. |
| Generacion automatica de respuestas | El sistema no redacta ni sintetiza texto. Devuelve los documentos y fragmentos que coinciden con el termino buscado. |
| Recuperacion semantica | No se calculan embeddings ni se utiliza base de datos vectorial. La busqueda es lexica y determinista. |
| Reconocimiento optico de caracteres (OCR) | Los PDF escaneados como imagen no generan texto extraible. El documento sigue siendo consultable por sus metadatos. |
| Correccion o interpretacion del contenido | El sistema no corrige, resume ni interpreta el contenido documental. |

| Elemento excluido | Justificacion |
|---|---|
| Toma de decisiones | La aplicacion no sustituye el criterio profesional ni emite conceptos automaticos. |
| Acceso a documentos no autorizados | Por diseno, el sistema nunca expone documentos fuera del alcance del rol y el area del usuario. |

### Sobre la extraccion de texto

La extraccion de texto no constituye un componente de inteligencia artificial. Es una operacion de lectura de formato: se descomprime el contenedor del archivo y se recuperan las cadenas de texto almacenadas. No hay interpretacion, traduccion ni analisis del contenido.

# 6. Actores del sistema

| Actor | Descripcion | Funciones principales | Nivel |
|---|---|---|---|
| Administrador | Responsable del control general del sistema. | Gestionar usuarios, roles, permisos, areas, documentos, auditoria, respaldos y configuracion. | 3 |
| Responsable documental | Encargado de administrar el contenido documental. | Cargar, clasificar, actualizar, versionar, archivar y retirar documentos. Administrar categorias y casos. | 2 |
| Asesor | Usuario operativo que consulta informacion. | Buscar documentos autorizados, revisar el contenido y consultar su propio historial de busquedas. | 1 |
| Sistema | Componente automatizado. | Validar permisos, extraer texto de los archivos, calcular hashes de integridad, registrar la auditoria y ejecutar las tareas programadas. | - |

**Actor retirado**

El actor "Sistema de IA" de la version anterior queda eliminado. Sus funciones de recuperacion de informacion son reemplazadas por consultas SQL deterministas sobre los indices de texto de la base de datos.

# 7. Requerimientos funcionales

A continuacion se listan los requerimientos funcionales del sistema. La columna "Prioridad" indica la criticidad de cada uno.

## 7.1. Autenticacion y usuarios

| ID | Requerimiento | Prioridad |
|---|---|---|
| RF-001 | El sistema debera permitir el inicio y el cierre de sesion con credenciales validas. | Alta |
| RF-002 | El administrador debera crear, editar, desactivar, bloquear y consultar usuarios. | Alta |
| RF-003 | El sistema debera aplicar permisos segun el rol y el area del usuario. | Alta |
| RF-004 | El sistema debera bloquear la cuenta tras cinco intentos fallidos de inicio de sesion. | Alta |
| RF-005 | El sistema debera cerrar la sesion tras el periodo de inactividad configurado. | Media |
| RF-006 | El usuario debera poder cambiar su propia contrasena validando la anterior. | Alta |
| RF-007 | El administrador debera poder restablecer la contrasena de un usuario, dejandola como temporal. | Media |
| RF-008 | El sistema debera permitir el registro publico de cuentas con rol Asesor unicamente. | Media |

## 7.2. Gestion documental

| ID | Requerimiento | Prioridad |
|---|---|---|
| RF-009 | Los usuarios autorizados podran cargar documentos en los formatos definidos. | Alta |
| RF-010 | El sistema debera validar el peso, la extension y el tipo MIME real del archivo antes de almacenarlo. | Alta |
| RF-011 | El sistema debera calcular un hash SHA-256 de cada archivo y rechazar los duplicados exactos. | Alta |
| RF-012 | Cada documento debera tener titulo, codigo, categoria, fecha, area y responsable antes de estar disponible. | Alta |

| ID | Requerimiento | Prioridad |
|---|---|---|
| RF-013 | El sistema debera extraer el texto de los archivos PDF, DOCX, XLSX y TXT para ampliar la busqueda. | Alta |
| RF-014 | Los usuarios autorizados podran editar los metadatos de un documento. | Alta |
| RF-015 | Los usuarios autorizados podran cargar nuevas versiones conservando las anteriores. | Alta |
| RF-016 | El sistema debera permitir archivar y marcar como eliminado un documento, conservando la trazabilidad. | Alta |
| RF-017 | Solo el administrador podra eliminar definitivamente un documento, previa confirmacion por codigo. | Media |
| RF-018 | El sistema debera verificar la integridad del archivo mediante su hash antes de cada descarga. | Alta |
| RF-019 | El sistema debera permitir la descarga de cualquier version anterior del documento. | Media |
| RF-020 | El sistema debera soportar al menos los formatos PDF, DOCX, DOC, XLSX, XLS y TXT. | Alta |
| RF-021 | El sistema debera permitir asociar etiquetas libres a los documentos. | Media |

## 7.3. Busqueda y consulta documental

| ID | Requerimiento | Prioridad |
|---|---|---|
| RF-022 | El usuario debera poder buscar documentos por palabras clave. | Alta |
| RF-023 | La busqueda debera abarcar titulo, codigo, descripcion, palabras clave y el texto extraido del archivo. | Alta |
| RF-024 | El sistema debera calcular y mostrar un puntaje de coincidencia para ordenar los resultados. | Media |
| RF-025 | El sistema debera mostrar el fragmento exacto donde aparece el termino buscado, resaltado. | Alta |
| RF-026 | El usuario debera poder filtrar por categoria, area, caso, estado, confidencialidad, etiqueta y rango de fechas. | Media |
| RF-027 | El sistema debera indicar claramente cuando no encuentre informacion suficiente, ofreciendo sugerencias. | Alta |
| RF-028 | El sistema debera registrar cada consulta realizada con su tiempo de respuesta y resultados. | Media |
| RF-029 | El usuario debera poder consultar el detalle y las fuentes de sus consultas anteriores. | Media |
| RF-030 | El sistema debera impedir que la busqueda exponga documentos fuera del alcance del usuario. | Alta |

## 7.4. Clasificacion y catalogos

| ID | Requerimiento | Prioridad |
|---|---|---|
| RF-031 | El sistema debera permitir administrar las categorias documentales. | Alta |
| RF-032 | El sistema debera permitir administrar los casos o expedientes y asociarlos a las areas. | Media |
| RF-033 | El administrador debera poder administrar las areas de la organizacion. | Alta |
| RF-034 | Una categoria o caso con documentos asociados no podra eliminarse, solo desactivarse o archivarse. | Alta |
| RF-035 | El sistema debera clasificar cada documento con un nivel de confidencialidad: publico, interno, reservado o confidencial. | Alta |
| RF-036 | Para los documentos reservados, el sistema debera permitir otorgar permisos a usuarios o areas concretas. | Alta |

### 7.5. Auditoria, respaldo y reportes

| ID | Requerimiento | Prioridad |
|---|---|---|
| RF-037 | El sistema debera registrar en una bitacora los accesos, cargas, modificaciones, descargas y eliminaciones. | Alta |
| RF-038 | La bitacora debera conservar el estado anterior y posterior de cada cambio. | Media |
| RF-039 | El administrador debera poder filtrar y exportar la bitacora a formato CSV. | Media |
| RF-040 | El administrador debera poder aplicar politicas de retencion y depurar registros antiguos. | Media |
| RF-041 | El administrador debera poder generar copias de seguridad completas o solo de datos. | Alta |
| RF-042 | El sistema debera permitir descargar y eliminar los archivos de respaldo. | Alta |
| RF-043 | El sistema debera presentar indicadores de uso, documentos y consultas en el panel principal. | Media |
| RF-044 | El sistema debera exportar el inventario documental, el historial de consultas y el listado de usuarios a CSV. | Media |
| RF-045 | El sistema debera generar una version imprimible del reporte de indicadores. | Baja |
| RF-046 | El sistema debera notificar al usuario sobre el estado de procesamiento de sus cargas. | Baja |
| RF-047 | El administrador debera poder modificar los parametros generales del sistema. | Media |
| RF-048 | El sistema debera enviar a la papelera logica los documentos eliminados, conservando sus archivos. | Media |

**Requerimientos retirados de la version 1.0**

Se eliminan los requerimientos por depender de inteligencia artificial: "Chat documental", "Recuperacion contextual", "Respuestas fundamentadas", "Fuentes de respuesta generada", "OCR" y "Evaluacion IA". El requerimiento de "Fuentes" se reformula como RF-025: mostrar el fragmento donde aparece el termino buscado dentro del documento original. El requerimiento "Multi-formato" se conserva como RF-020 pero sin OCR.

## 8. Requerimientos no funcionales

| ID | Categoria | Requerimiento |
|---|---|---|
| RNF-001 | Seguridad | Las contrasenas se almacenan con hash bcrypt. Ninguna credencial se guarda en texto plano. |
| RNF-002 | Seguridad | Todas las consultas a la base de datos usan sentencias preparadas para prevenir inyeccion SQL. |
| RNF-003 | Seguridad | Todo texto mostrado al usuario se escapa para prevenir XSS. |
| RNF-004 | Seguridad | Los formularios POST incluyen y validan un token CSRF por sesion. |
| RNF-005 | Confidencialidad | Los documentos no se exponen a usuarios sin permisos sobre su area o nivel de confidencialidad. |
| RNF-006 | Integridad | Cada archivo se verifica mediante hash SHA-256 antes de su descarga. |
| RNF-007 | Integridad | La validacion del tipo de archivo se realiza sobre el contenido real, no sobre la extension declarada. |
| RNF-008 | Rendimiento | Las busquedas deberan resolverse en menos de 3 segundos para el 90 % de las consultas sobre un volumen de 10 000 documentos. |
| RNF-009 | Disponibilidad | Disponibilidad minima del 99 % en el horario operativo definido. |

| ID | Categoria | Requerimiento |
|---|---|---|
| RNF-010 | Capacidad | Soporte inicial para 50 usuarios concurrentes y 10 000 documentos. |
| RNF-011 | Escalabilidad | La arquitectura debera permitir incorporar nuevos modulos sin reescribir el nucleo. |
| RNF-012 | Usabilidad | La interfaz debera ser comprensible para usuarios con conocimientos basicos de ofimatica. |
| RNF-013 | Trazabilidad | Toda operacion relevante quedara registrada con usuario, fecha, direccion IP y resultado. |
| RNF-014 | Mantenibilidad | El codigo estara modularizado siguiendo el patron MVC y documentado. |
| RNF-015 | Mantenibilidad | Las hojas de estilo estaran separadas por responsabilidad y cargadas en orden de cascada definido. |
| RNF-016 | Respaldo | Deberan existir mecanismos de copia y recuperacion. RPO maximo 24 h y RTO maximo 4 h. |
| RNF-017 | Idioma | La interfaz y todos los mensajes estaran en espanol. |
| RNF-018 | Accesibilidad | Debera cumplir criterios basicos WCAG 2.1 AA: contraste suficiente, foco visible y navegacion por teclado. |
| RNF-019 | Compatibilidad | La aplicacion debera funcionar en las versiones actuales de Chrome, Edge y Firefox. |
| RNF-020 | Auditoria | Los registros de auditoria se conservaran minimo 12 meses. |
| RNF-021 | Privacidad | La solucion respetara las politicas internas y la normativa aplicable sobre proteccion de datos. |
| RNF-022 | Portabilidad | La aplicacion debera operar en cualquier servidor con PHP 8 y MySQL 8 sin dependencias externas. |

**Requerimientos no funcionales retirados**

Se eliminan "Confiabilidad de IA" (indicar cuando no existe evidencia suficiente generada por un modelo) y "Cifrado" en su forma original asociada a los embeddings. La indicacion de ausencia de informacion se conserva, pero como requerimiento funcional RF-027, aplicado al buscador.

## 9. Reglas de negocio

1. Solo los usuarios autenticados acceden al sistema.
2. Los permisos determinan que documentos puede consultar cada usuario.
3. El nivel de acceso del rol y el area del usuario determinan el alcance de la consulta.
4. Solo los usuarios con permiso de creacion cargan documentos.
5. Todo documento debe tener identificacion y metadatos minimos antes de estar disponible.
6. Un documento reservado o confidencial solo es accesible si existe un permiso explicito.
7. Si la informacion buscada no esta presente, el sistema debe comunicarlo claramente.
8. El sistema no interpreta, resume ni genera contenido: solo devuelve coincidencias.
9. Las acciones criticas deben quedar registradas en la auditoria.
10. Una categoria o caso con documentos asociados no se elimina, se desactiva.
11. La eliminacion definitiva esta restringida al administrador y exige confirmacion por codigo.
12. Los archivos no se eliminan del servidor mientras exista una version registrada, salvo en la eliminacion definitiva.
13. Un archivo con el mismo hash de otro ya registrado se rechaza por duplicado.
14. Las contrasenas deben cumplir la politica de complejidad definida.

15. Los registros de auditoria no pueden ser modificados ni eliminados por usuarios no administradores.

## 10. Casos de uso principales

| ID | Caso de uso | Actor principal | Requerimientos |
|---|---|---|---|
| CU-01 | Iniciar sesion | Todos | RF-001, RF-004, RF-005 |
| CU-02 | Cerrar sesion | Todos | RF-001 |
| CU-03 | Gestionar usuarios y roles | Administrador | RF-002, RF-003 |
| CU-04 | Gestionar areas | Administrador | RF-033 |
| CU-05 | Cargar documento | Responsable documental | RF-009 a RF-013 |
| CU-06 | Clasificar documento | Responsable documental | RF-012, RF-035, RF-036 |
| CU-07 | Cargar nueva version | Responsable documental | RF-015, RF-019 |
| CU-08 | Editar metadatos | Responsable documental | RF-014 |
| CU-09 | Archivar o eliminar documento | Administrador | RF-016, RF-017, RF-048 |
| CU-10 | Buscar documentos | Asesor, Responsable | RF-022 a RF-026 |
| CU-11 | Revisar el fragmento encontrado | Asesor | RF-025 |
| CU-12 | Descargar documento | Segun permisos | RF-018, RF-019 |
| CU-13 | Consultar historial propio | Asesor | RF-028, RF-029 |
| CU-14 | Revisar auditoria | Administrador | RF-037 a RF-040 |
| CU-15 | Generar respaldo | Administrador | RF-041, RF-042 |
| CU-16 | Consultar indicadores | Administrador | RF-043 |
| CU-17 | Exportar reportes | Administrador | RF-044, RF-045 |
| CU-18 | Configurar el sistema | Administrador | RF-047 |
| CU-19 | Validar permisos | Sistema | RF-003, RF-030, RNF-005 |
| CU-20 | Registrar auditoria | Sistema | RF-037, RNF-013 |

**Casos de uso retirados**

Se eliminan los casos "Recuperar informacion relevante" y "Generar respuesta fundamentada", ambos asignados al Sistema de IA en la version anterior. La recuperacion de informacion ahora es una operacion de consulta SQL, cubierta por CU-10.

# 11. Arquitectura conceptual

La aplicacion sigue el patron Modelo-Vista-Controlador (MVC) sobre una arquitectura web clasica de tres capas. No existen componentes de inteligencia artificial ni servicios externos de inferencia.

## 11.1. Capas del sistema

| Capa | Responsabilidad | Componentes |
|---|---|---|
| Presentacion | Interfaz con el usuario. Estructura HTML, presentacion CSS e interacciones en JavaScript. | Vistas PHP, 7 hojas de estilo modulares, app.js |
| Control | Recibe la peticion, valida los datos, aplica las reglas de negocio y selecciona la vista. | 7 controladores, enrutador index.php |
| Modelo | Acceso a datos y representacion de las entidades del dominio. | 6 modelos, capa PDO |
| Nucleo | Servicios transversales reutilizables por todos los modulos. | Database, Sesion, Helper, Validador, Auditoria, GestorArchivos |
| Persistencia | Almacenamiento estructurado de la informacion. | MySQL 8.0 con InnoDB y utf8mb4 |
| Almacenamiento | Conservacion de los archivos originales en el sistema de archivos. | public/uploads organizado por ano y mes |

## 11.2. Flujo de una peticion

Toda peticion sigue la misma secuencia, garantizando que los controles de seguridad se apliquen de forma uniforme:

1. El navegador solicita index.php indicando modulo y accion.
2. El enrutador carga la configuracion, el nucleo y los modelos.
3. Se inicia o recupera la sesion y se verifica la autenticacion.
4. Se comprueba el permiso del rol para el modulo solicitado.
5. Si la peticion es POST, se valida el token CSRF.
6. El controlador valida los datos de entrada con la clase Validador.
7. El modelo ejecuta las consultas SQL mediante sentencias preparadas.
8. La accion se registra en la bitacora de auditoria.
9. Se carga la vista correspondiente con los datos obtenidos.
10. El resultado se devuelve al navegador.

## 11.3. Componentes retirados

| Componente de la version 1.0 | Estado en la version 2.0 |
|---|---|
| Capa RAG (recuperacion y generacion) | Eliminada por completo |
| Base de datos vectorial (pgvector, Qdrant) | Eliminada; se usan indices FULLTEXT de MySQL |
| Modelo de lenguaje (LLM) | Eliminado |
| Generacion de embeddings | Eliminada |
| Framework de orquestacion (LangChain, LlamaIndex) | Eliminado |
| Chat conversacional | Reemplazado por formulario de busqueda |
| OCR (Tesseract) | Eliminado |
| Generacion automatica de respuestas | Eliminada |

# 12. Seguridad

El sistema implementa los siguientes mecanismos de proteccion, verificables en el codigo fuente:

| Mecanismo | Implementacion tecnica |
|---|---|
| Almacenamiento de contrasenas | Hash bcrypt generado con password_hash() con coste 10. Nunca se almacena ni se transmite la contrasena en texto plano. |
| Prevencion de inyeccion SQL | El 100 % de las consultas utiliza sentencias preparadas con PDO y parametros vinculados. No se concatenan valores en el SQL. |
| Prevencion de XSS | Todo dato mostrado se procesa con htmlspecialchars() con las banderas ENT_QUOTES y ENT_SUBSTITUTE. |
| Proteccion CSRF | Cada sesion genera un token aleatorio de 32 bytes que se valida con hash_equals() en todos los formularios POST. |
| Fijacion de sesion | Se ejecuta session_regenerate_id(true) al autenticar al usuario. |
| Seguridad de cookies | Las cookies de sesion se emiten con HttpOnly y SameSite=Lax. |
| Control de inactividad | La sesion se cierra automaticamente tras el periodo configurado (30 minutos por defecto). |
| Proteccion contra fuerza bruta | El contador de intentos fallidos se incrementa en cada fallo. Al llegar a cinco, un trigger marca la cuenta como bloqueada. |
| Validacion de archivos | Se verifica el tipo MIME real con finfo y se compara contra una lista blanca por extension. No se confia en el tipo declarado por el navegador. |
| Prevencion de path traversal | Antes de eliminar un archivo se comprueba con realpath que la ruta resuelta este dentro de la carpeta de cargas. |
| Nombres de archivo seguros | Los archivos se guardan con un nombre generado aleatoriamente, lo que evita sobrescrituras y la ejecucion de nombres maliciosos. |
| Integridad de archivos | Cada archivo tiene un hash SHA-256 que se verifica antes de cada descarga. Si no coincide, la descarga se cancela y se registra. |
| Control de acceso (RBAC) | Tres niveles de acceso y una matriz de permisos por modulo con operaciones de ver, crear, editar y eliminar. |
| Control de acceso (ABAC) | El area del usuario y el nivel de confidencialidad del documento restringen el alcance de forma adicional al rol. |
| Permisos explicitos | Los documentos reservados o confidenciales requieren una autorizacion nominal por usuario o por area. |
| Auditoria | Toda accion critica se registra con usuario, fecha, direccion IP, navegador, resultado y los estados anterior y posterior. |
| Manejo de errores | En produccion no se exponen mensajes tecnicos al usuario. Los errores se registran en archivo y en la tabla log_errores. |

**Cifrado en reposo**

El cifrado del almacenamiento se delega a la infraestructura (cifrado de disco o volumen). La aplicacion no implementa cifrado propio de archivos, ya que la version anterior delegaba esta funcion a un componente retirado. Se recomienda habilitar BitLocker o LUKS en el servidor de produccion.

# 13. Flujo de la consulta documental

Este apartado reemplaza por completo al componente RAG de la version anterior. Describe como el sistema localiza informacion sin recurrir a inteligencia artificial.

## 13.1. Secuencia de la busqueda

1. El usuario escribe uno o varios terminos en el buscador.
2. Opcionalmente selecciona filtros: categoria, area, caso, estado, confidencialidad, etiqueta y rango de fechas.
3. El sistema construye la clausula de acceso segun el rol y el area del usuario. Esta condicion se aplica siempre, antes de cualquier criterio de busqueda.
4. Se ejecuta una consulta SQL con coincidencia parcial de texto sobre cinco campos: titulo, codigo, descripcion, palabras clave y el texto extraido del archivo.
5. Para cada resultado se calcula un puntaje ponderado: 100 puntos si coincide el titulo, 60 si coinciden las palabras clave, 30 si coincide la descripcion, 20 si coincide el codigo y 10 si coincide el texto extraido.
6. Los resultados se ordenan de mayor a menor puntaje.
7. Se localiza la posicion del termino dentro del texto y se extrae un fragmento de contexto de 320 caracteres alrededor de la coincidencia.
8. El termino buscado se resalta visualmente dentro del fragmento.
9. La consulta se registra con su texto, filtros, cantidad de resultados y tiempo de respuesta en milisegundos.
10. Si no hay coincidencias, se informa al usuario y se le presentan sugerencias concretas para reformular la busqueda.

## 13.2. Extraccion de texto de los archivos

La extraccion amplia el alcance de la busqueda al interior de los documentos. Es una operacion de lectura de formato, no de interpretacion de contenido.

| Formato | Metodo de extraccion | Requisito tecnico |
|---|---|---|
| TXT | Lectura directa del archivo con deteccion de codificacion y conversion a UTF-8. | Ninguno |
| DOCX | Descompresion del contenedor ZIP y lectura del documento XML interno, eliminando las etiquetas. | Extension zip de PHP |
| XLSX | Descompresion del contenedor y lectura del archivo de cadenas compartidas y de los valores de cada hoja. | Extension zip de PHP |
| PDF | Lectura basica de los flujos de contenido de texto de archivos no cifrados. | Ninguno |
| DOC / XLS | No soportado. Son formatos binarios propietarios que requieren conversion externa. | - |

**Limitaciones conocidas de la extraccion**

Los documentos PDF escaneados como imagen no contienen texto recuperable, por lo que no aportan contenido al buscador; siguen siendo localizables por sus metadatos. Los archivos protegidos con contrasena tampoco pueden procesarse. Estas limitaciones no se resuelven con OCR, porque esa tecnologia fue retirada del alcance.

## 13.3. Comparacion con la version anterior

| Aspecto | Version 1.0 (con IA) | Version 2.0 (actual) |
|---|---|---|
| Forma de consultar | Chat en lenguaje natural | Formulario de busqueda con palabras clave |
| Procesamiento | Embeddings y modelo de lenguaje | Consulta SQL con coincidencia de texto |
| Origen de la respuesta | Texto generado por el modelo | Fragmento literal del documento original |
| Trazabilidad de la fuente | Referencia inferida por el modelo | Fragmento exacto con posicion verificable |
| Riesgo de informacion inventada | Presente | Nulo: el sistema no genera texto |
| Dependencia externa | Modelo local o proveedor externo | Ninguna |
| Requisitos de hardware | CPU o GPU para inferencia | Servidor web convencional |
| Requisitos de software | Python, contenedores, base vectorial | PHP y MySQL unicamente |

# 14. Infraestructura y tecnologia

## 14.1. Tecnologias utilizadas

| Componente | Tecnologia |
|---|---|
| Frontend - estructura | HTML5 |
| Frontend - presentacion | CSS3 en siete hojas modulares cargadas en orden de cascada: tokens, layout, formularios, componentes, avisos, autenticacion e impresion. |
| Frontend - interactividad | JavaScript sin dependencias externas: validacion de formularios, modales, medidor de contrasena, zona de carga y confirmaciones. |
| Backend | PHP 8 con arquitectura MVC y programacion orientada a objetos. |
| Base de datos | MySQL 8.0 con motor InnoDB y cotejamiento utf8mb4. |
| Administracion de la base de datos | MySQL Workbench 8.0. |
| Servidor web | Apache (XAMPP) o el servidor integrado de PHP. |
| Versionamiento del esquema | Tres scripts SQL secuenciales reproducibles. |

## 14.2. Componentes retirados respecto a la version 1.0

| Componente anterior | Reemplazo en la version actual |
|---|---|
| React 18 + TypeScript + Vite + Tailwind + shadcn/ui | HTML5, CSS3 y JavaScript sin dependencias |
| Python 3.12 + FastAPI + SQLAlchemy 2.0 | PHP 8 sin frameworks |
| PostgreSQL 16 y pgvector | MySQL 8.0 con indices FULLTEXT |
| PostgreSQL FTS y Qdrant | MySQL FULLTEXT y busqueda por coincidencia |
| PyMuPDF, python-docx, Tesseract OCR | Extraccion nativa en PHP con ZipArchive y funciones de cadena |
| LangChain / LlamaIndex | Consultas SQL deterministas |
| Embeddings BGE-M3 o E5 | Eliminado |
| Ollama / vLLM con Llama 3.1, Mistral o Qwen | Eliminado |
| MinIO o S3 | Sistema de archivos del servidor |
| JWT + OAuth2 | Sesiones PHP nativas con cookies HttpOnly |
| Prometheus, Grafana, Loki, Sentry | Tabla log_errores y bitacora de auditoria |
| Docker y Docker Compose | Instalacion directa sobre XAMPP |

## 14.3. Requisitos de infraestructura

| Recurso | Requisito minimo | Recomendado |
|---|---|---|
| Procesador | 2 nucleos | 4 nucleos |
| Memoria RAM | 4 GB | 8 GB |
| Almacenamiento | 20 GB | 100 GB con respaldo externo |
| Sistema operativo | Windows, Linux o macOS | Linux en produccion |
| PHP | 8.0 con pdo_mysql, fileinfo, zip y mbstring | 8.2 o superior |

| Recurso | Requisito minimo | Recomendado |
|---|---|---|
| MySQL | 8.0 | 8.0 con respaldo automatizado |
| Conectividad | Red local o intranet | HTTPS con certificado TLS |
| Unidad de respaldo | Carpeta compartida | Almacenamiento externo o en red |

**Reduccion significativa de requisitos**

Al eliminar los componentes de inteligencia artificial, el sistema ya no requiere GPU, ni memoria adicional para el modelo de lenguaje, ni una base de datos vectorial, ni contenedores. Esto reduce de forma notable el costo de infraestructura y simplifica la operacion, que ahora se limita a un servidor web con PHP y MySQL.

# 15. Modelo de datos

La base de datos se denomina gestor_documental y consta de veinte tablas con motor InnoDB y cotejamiento utf8mb4. Se complementa con cinco triggers, siete vistas, tres procedimientos almacenados y tres eventos programados.

## 15.1. Tablas del sistema

| Grupo | Tabla | Proposito |
|---|---|---|
| Seguridad | roles | Perfiles de acceso con su nivel de privilegio |
| Seguridad | areas | Dependencias de la organizacion |
| Seguridad | usuarios | Cuentas con credenciales y estado |
| Seguridad | permisos_rol | Matriz de permisos por rol y modulo |
| Seguridad | sesiones_usuario | Control de sesiones activas |
| Clasificacion | categorias | Categorias documentales |
| Clasificacion | casos | Expedientes o procesos |
| Clasificacion | etiquetas | Etiquetas libres |
| Documental | documentos | Registro maestro con los metadatos |
| Documental | versiones_documento | Historial de archivos por version |
| Documental | documento_etiquetas | Relacion documento-etiqueta |
| Documental | permisos_documento | Autorizaciones sobre documentos reservados |
| Trazabilidad | consultas | Historial de busquedas |
| Trazabilidad | consulta_resultados | Documentos devueltos por cada busqueda |
| Trazabilidad | historial_descargas | Registro de descargas |
| Trazabilidad | auditoria | Bitacora general de acciones |
| Control | respaldos | Registro de copias de seguridad |
| Control | configuracion | Parametros del sistema |
| Control | notificaciones | Avisos a los usuarios |
| Control | log_errores | Bitacora de errores de la aplicacion |

## 15.2. Objetos programables

| Tipo | Nombre | Funcion |
|---|---|---|
| Trigger | tr_version_after_insert | Actualiza los contadores de versiones y garantiza que solo una version este marcada como vigente. |
| Trigger | tr_consulta_resultado_insert | Incrementa el contador de consultas del documento. |
| Trigger | tr_usuario_intento_fallido | Bloquea la cuenta al superar el limite de intentos fallidos. |
| Trigger | tr_usuario_bienvenida | Genera una notificacion de bienvenida al crear un usuario. |
| Trigger | tr_documento_publicado | Notifica al responsable cuando un documento pasa a publicado. |
| Vista | v_usuarios_completo | Usuarios con su rol y area resueltos |
| Vista | v_documentos_completo | Documentos con todos los metadatos y la version vigente |

| Tipo | Nombre | Funcion |
|---|---|---|
| Vista | v_auditoria_detalle | Bitacora con el nombre del usuario resuelto |
| Vista | v_estadisticas_documentos | Conteos por categoria para el panel |
| Vista | v_documentos_por_area | Distribucion documental por area |
| Vista | v_consultas_recientes | Historial de consultas con usuario |
| Vista | v_sesiones_activas | Sesiones abiertas en el sistema |
| Procedimiento | sp_registrar_auditoria | Registro estandarizado de eventos |
| Procedimiento | sp_documentos_visibles | Documentos visibles para un usuario segun su nivel y area |
| Procedimiento | sp_indicadores_panel | Resumen de indicadores del sistema |
| Evento | ev_cerrar_sesiones_inactivas | Cierra sesiones inactivas cada 15 minutos |
| Evento | ev_limpiar_notificaciones | Elimina notificaciones leidas de mas de 90 dias |
| Evento | ev_limpiar_errores | Elimina errores de mas de 180 dias |

### 15.3. Niveles de confidencialidad

| Nivel | Quien puede consultarlo |
|---|---|
| PUBLICO | Cualquier usuario autenticado, sin importar su area. |
| INTERNO | Usuarios del area responsable y responsables documentales. |
| RESERVADO | Solo usuarios o areas con permiso explicito otorgado. |
| CONFIDENCIAL | Solo usuarios o areas explicitamente autorizados por el administrador. |

## 16. Criterios de aceptacion

El sistema se considera aceptado cuando se cumplen verificablemente los siguientes criterios:

1. Un administrador puede crear un usuario, asignarle un rol y verificar que quede registrado.
2. Un usuario autorizado puede cargar un documento y verificar su estado.
3. El sistema rechaza un archivo cuyo tipo real no corresponda a su extension.
4. El sistema rechaza un archivo que supere el peso maximo configurado.
5. El sistema rechaza un archivo identico a otro ya registrado, indicando cual es.
6. Un asesor solo puede consultar los documentos permitidos para su rol, area y nivel de confidencialidad.
7. Al intentar abrir un documento fuera de su alcance, el asesor recibe un mensaje de acceso denegado.
8. El usuario puede buscar por palabras clave y recibe los documentos coincidentes ordenados por relevancia.
9. Cada resultado muestra el fragmento exacto donde aparece el termino, con el termino resaltado.
10. Cuando no hay coincidencias, el sistema lo informa y ofrece sugerencias.
11. Los filtros avanzados restringen correctamente los resultados.
12. Al cargar una nueva version, la anterior se conserva y puede descargarse.
13. La verificacion de integridad confirma que el hash del archivo coincide con el registrado.
14. Todas las acciones criticas aparecen en la bitacora con usuario, fecha y direccion IP.
15. Un usuario sin sesion es redirigido al inicio de sesion en cualquier modulo protegido.

16. Tras cinco intentos fallidos, la cuenta queda bloqueada automaticamente.
17. El administrador puede generar un respaldo y descargarlo en formato SQL.
18. Los reportes se exportan correctamente a formato CSV y son legibles en Excel.
19. La version imprimible del reporte de indicadores se genera sin errores.
20. La interfaz es legible y operable en una pantalla de 1366 x 768 pixeles.

**Criterios retirados**

Se eliminan los criterios de la version anterior referidos a "respuestas sustentadas en contenido recuperado", "respuestas fundamentadas" y "alucinaciones verificadas". Al no existir generacion automatica de texto, estos criterios dejan de ser aplicables.

# 17. Riesgos

| ID | Riesgo | Impacto | Mitigacion |
|---|---|---|---|
| R-01 | Acceso indebido a documentos reservados | Alto | RBAC por rol, ABAC por area, niveles de confidencialidad, permisos explicitos y auditoria de cada intento denegado. |
| R-02 | Carga de archivos maliciosos | Alto | Validacion del tipo MIME real con finfo, lista blanca de extensiones, renombrado aleatorio de archivos y bloqueo de ejecucion en la carpeta de cargas. |
| R-03 | Perdida de informacion | Alto | Respaldo completo de la base de datos, copia periodica de la carpeta de archivos y almacenamiento del respaldo fuera del servidor. |
| R-04 | Documentos desactualizados o duplicados | Medio | Versionado obligatorio, rechazo de archivos duplicados por hash y revision periodica del inventario. |
| R-05 | Degradacion del rendimiento por volumen | Medio | Indices sobre los campos de filtro, indices FULLTEXT para el texto y paginacion obligatoria en todos los listados. |
| R-06 | Extraccion de texto incompleta | Medio | Documentacion clara de las limitaciones. Los documentos siguen siendo localizables por sus metadatos y palabras clave. |
| R-07 | Credenciales de demostracion en produccion | Alto | El sistema obliga al cambio de contrasena en el primer ingreso y solicita el cambio en el panel de perfil. |
| R-08 | Configuracion incorrecta de permisos de carpeta | Medio | Verificacion de permisos en la pantalla de configuracion e instrucciones explicitas en la documentacion de instalacion. |
| R-09 | Fallo en la generacion del respaldo | Medio | Manejo de errores con registro del fallo y recomendacion de usar mysqldump como alternativa desde linea de comandos. |
| R-10 | Sesiones abandonadas abiertas | Medio | Cierre automatico por inactividad y evento programado que depura las sesiones inactivas cada quince minutos. |

**Riesgos eliminados**

Desaparecen los riesgos propios de la inteligencia artificial: alucinaciones del modelo, dependencia de un proveedor externo de IA y mala extraccion mediante OCR. Al no existir generacion de texto, el sistema no puede producir informacion que no este en los documentos registrados.

# 18. Fases del proyecto

| Fase | Actividad | Entregable |
|---|---|---|
| 1 | Levantamiento y validacion de requerimientos | Documento de requerimientos aprobado |
| 2 | Diseno de la base de datos y del modelo de seguridad | Scripts SQL de estructura, objetos y datos iniciales |
| 3 | Desarrollo de la autenticacion, los usuarios y los permisos | Modulo de acceso y modulo de usuarios funcionales |
| 4 | Desarrollo del modulo de gestion documental | Carga, versionado, edicion y descarga de documentos |
| 5 | Implementacion de la busqueda y los filtros avanzados | Buscador funcional con extraccion de texto |
| 6 | Desarrollo de la auditoria y los respaldos | Bitacora consultable y generacion de copias SQL |
| 7 | Desarrollo de reportes e indicadores | Panel de indicadores y exportacion a CSV |
| 8 | Pruebas funcionales, de seguridad y de usabilidad | Informe de pruebas y correcciones aplicadas |

| Fase | Actividad | Entregable |
|---|---|---|
| 9 | Implementacion piloto | Sistema en operacion con un grupo reducido de usuarios |
| 10 | Capacitacion, documentacion y puesta en produccion | Manual de usuario y sistema en produccion |

## 19. Informacion pendiente de validar

Los siguientes aspectos requieren confirmacion por parte de la organizacion antes de la puesta en produccion:

| Aspecto | Dato requerido |
|---|---|
| Volumen documental | Cantidad de documentos actuales y crecimiento mensual estimado. |
| Formatos utilizados | Proporcion de cada formato para dimensionar la extraccion de texto. |
| Usuarios y perfiles | Numero de usuarios por rol y distribucion por areas. |
| Clasificacion actual | Estructura de categorias y casos vigente en la organizacion. |
| Confidencialidad | Criterios para clasificar un documento como reservado o confidencial. |
| Politica de contrasenas | Requisitos de complejidad y vigencia definidos por la organizacion. |
| Retencion documental | Plazos de conservacion y procedimiento de eliminacion autorizada. |
| Infraestructura | Servidor disponible, sistema operativo y capacidad de almacenamiento. |
| Modalidad de acceso | Acceso local, en intranet o remoto mediante VPN. |
| Respaldo | Frecuencia requerida y ubicacion del almacenamiento externo. |
| Certificado TLS | Disponibilidad de un certificado para habilitar HTTPS en produccion. |
| Politica de proteccion de datos | Normativa aplicable y responsable del tratamiento de la informacion. |

# Resumen del cambio de alcance

La version 2.0 de este documento redefine el proyecto como un sistema de gestion y consulta documental construido exclusivamente con HTML, CSS, PHP y MySQL, administrado mediante MySQL Workbench.

Los cambios principales respecto a la version 1.0 son:

| Aspecto | Version 1.0 | Version 2.0 |
|---|---|---|
| Tecnologias | React, Python, PostgreSQL, Docker, modelos de lenguaje | HTML, CSS, PHP y MySQL |
| Consulta | Chat en lenguaje natural con respuestas generadas | Buscador por palabras clave con filtros avanzados |
| Resultado al usuario | Texto redactado por el modelo | Fragmento literal del documento original |
| Componentes de IA | RAG, embeddings, LLM, OCR | Ninguno |
| Base de datos vectorial | pgvector o Qdrant | No aplica |
| Hardware requerido | CPU o GPU para inferencia | Servidor web convencional |
| Costo de infraestructura | Elevado por los recursos de IA | Reducido a un servidor web y una base de datos |
| Riesgo de informacion inventada | Presente | Inexistente por diseno |
| Complejidad de mantenimiento | Alta, multiples tecnologias | Baja, un solo lenguaje de servidor |

**Consideracion final**

La decision de retirar la inteligencia artificial simplifica de forma significativa el desarrollo, la operacion y el mantenimiento del sistema. El resultado es una aplicacion mas predecible, mas economica de operar y con trazabilidad total: cada dato mostrado al usuario proviene directamente de un documento registrado por la organizacion, sin intermediacion de ningun proceso de inferencia.

*- Fin del documento -*